

# Controlo de Dispositivos Inteligentes com Interfaces Cérebro-Computador (BCI)

3.º Ano, Licenciatura em Engenharia Informática  
Laboratório de Projeto em Engenharia Informática

Orientador Principal - Arsénio Monteiro dos Reis.  
Coorientadores- Tânia Rocha; Eduardo Pires, Pedro Dias.

Pedro Santos – AL80038

Pedro Sampaio – AL79431

Maio de 2025

## Resumo

Este relatório explora o potencial das Interfaces Cérebro-Computador (BCI) com foco na utilização de um dispositivo EEG comercial, o NeuroSky Mindwave Mobile 2, e na integração com sistemas domóticos através de técnicas de aprendizagem automática. Através da captação de sinais elétricos do cérebro, como as ondas alfa, beta, gamma, delta e theta, foi possível identificar padrões associados a estados mentais como concentração e relaxamento. Utilizando um modelo de classificação treinado com dados recolhidos em tempo real, foi desenvolvida uma aplicação que prevê o estado mental do utilizador e atua sobre uma lâmpada inteligente, ligando-a ou desligando-a conforme o nível de atenção. O projeto evidencia o potencial das BCIs em cenários práticos de interação sem contacto físico, apontando ainda caminhos para futuras aplicações em jogos, saúde, acessibilidade e automação.

**Palavras-chave:** Brain-Computer Interface (BCI), Electroencefalografia (EEG), Machine Learning, Smart Home, NeuroSky, Interação sem contacto, Automação, Atenção, Relaxamento.

# Índice

<b>1</b>	<b>Introdução</b>	<b>3</b>
<b>2</b>	<b>Fundamentos das Interfaces Cérebro-Computador</b>	<b>3</b>
2.1	Tipos de sensores	3
<b>3</b>	<b>Ondas Cerebrais e Sinais Captados</b>	<b>3</b>
<b>4</b>	<b>Dispositivos Comerciais e Projetos Associados</b>	<b>4</b>
4.1	Dispositivos populares	4
4.2	Tabela comparativa de dispositivos BCI	5
<b>5</b>	<b>Tecnologias Utilizadas</b>	<b>5</b>
5.1	Dispositivo EEG: Neurosky Mindwave Mobile 2	5
5.2	Think Gear Connector (TGC)	5
5.3	Softwares e Linguagens	5
5.4	Lâmpada Inteligente	6
<b>6</b>	<b>Trabalho Prático Desenvolvido</b>	<b>6</b>
6.1	Escolha do dispositivo e primeiros desafios	6
6.2	Instalação e comunicação com o TGC	6
6.3	Recolha de dados e criação do dataset	7
6.4	Processamento e treino do modelo	7
6.5	Integração em tempo real e controlo da lâmpada	7
<b>7</b>	<b>Avaliação do Modelo</b>	<b>8</b>
<b>8</b>	<b>Aplicações Práticas e Estado da Arte</b>	<b>9</b>
<b>9</b>	<b>Futuro da tecnologia BCI</b>	<b>10</b>
<b>10</b>	<b>Casos de Estudo Recentes em Interfaces Cérebro-Computador (2020–2025)</b>	<b>10</b>
10.1	Comunicação Restaurada em Paciente com Esclerose Lateral Amiotrófica (ELA) através de BCI	10
10.2	Uso de BCI em Programa Terapêutico para Adolescente com Autismo e TDAH	11
10.3	Controlo de Dispositivos Inteligentes via Pensamento em Paciente com Paralisia	11
<b>11</b>	<b>Conclusão</b>	<b>11</b>
<b>12</b>	<b>Referências</b>	<b>12</b>

# 1 Introdução

As interfaces cérebro-computador (BCIs) representam uma tecnologia emergente que visa conectar o cérebro humano diretamente a sistemas computacionais. Este avanço permite que sinais neuronais sejam utilizados para controlar dispositivos, dispensando movimentos físicos. Originalmente desenvolvidas para fins médicos, as BCIs têm vindo a ganhar relevância em domínios como entretenimento, educação e automação residencial.

Este trabalho visa explorar os fundamentos das BCIs, descrevendo os tipos de sinais captados, os sensores utilizados (molhados e secos), como esses sinais são processados, e as aplicações práticas. O relatório também aborda as soluções comerciais existentes e apresenta uma análise do kit OpenBCI, usado no nosso projeto para controlar dispositivos IoT.

## 2 Fundamentos das Interfaces Cérebro-Computador

Uma Interface Cérebro-Computador (BCI) é um sistema que traduz sinais cerebrais em comandos que podem ser interpretados por computadores ou outros dispositivos. As BCIs são normalmente compostas por:

- Sensores que captam sinais neuronais
- Um sistema de aquisição de sinais
- Algoritmos de processamento e classificação
- Interface de aplicação (ex: mover o cursor, acender uma lâmpada)

### 2.1 Tipos de sensores

- **Molhados:** utilizam gel condutor. Maior condutividade, mas desconfortáveis para uso prolongado.
- **Secos:** mais confortáveis, mas captam sinais com menor qualidade.

## 3 Ondas Cerebrais e Sinais Captados


As ondas cerebrais são sinais elétricos resultantes da atividade neuronal no cérebro humano. Estas são categorizadas em bandas de frequência distintas, cada uma associada a diferentes estados mentais e cognitivos. A eletroencefalografia (EEG) é a técnica utilizada para captar estes sinais, permitindo a sua análise e interpretação em tempo real.

As principais bandas de frequência são:

- **Ondas Delta (0,5 a 4 Hz):** Associadas ao sono profundo e inconsciência. Alta atividade delta é comum durante o sono REM ou em estados de meditação profunda.
- **Ondas Theta (4 a 8 Hz):** Relacionadas com estados de relaxamento profundo, criatividade e devaneio.
- **Ondas Alpha (8 a 12 Hz):** Presentes em estados de relaxamento acordado, como

quando se fecha os olhos e se permanece calmo.

- **Ondas Beta (12 a 30 Hz):** Associadas à atenção ativa, foco e resolução de problemas.
- **Ondas Gamma (30 a 100 Hz ou mais):** Relacionadas a estados de alta atividade mental, como percepção sensorial, processamento cognitivo e aprendizagem.



*Figura 1 – Classificação das ondas cerebrais por frequência*

O dispositivo utilizado neste projeto não mede diretamente a frequência em hertz (Hz), mas sim a potência de cada uma destas bandas, ou seja, a energia com que essas ondas estão presentes no cérebro em dado momento. Esta potência é representada como valores inteiros obtidos através da aplicação de uma transformada de Fourier (FFT) no sinal EEG captado.

Em estados de alta concentração, por exemplo, é comum observar valores elevados nas bandas beta e gamma. Em contrapartida, em momentos de relaxamento, os valores nas bandas alpha e theta tendem a predominar.

## 4 Dispositivos Comerciais e Projetos Associados

### 4.1 Dispositivos populares

- NeuroSky MindWave Mobile 2
- Emotiv Epoc X
- OpenBCI Cyton
- Muse Headband
- NextMind (descontinuado)

## 4.2 Tabela comparativa de dispositivos BCI

Dispositivo	Sinal	Canais	Conectividade	Características
NeuroSky MindWave	EEG	2	Bluetooth	Portátil, acessível, foco/meditação
Emotiv Epoc X	EEG	14	USB/Bluetooth	Alta resolução, clínica e pesquisa
OpenBCI Cyton	EEG	8	USB	Open-source, sensores secos, usado em projetos universitários
Muse Headband	EEG	4	Bluetooth	Foco em meditação e biofeedback
NextMind	EEG	1	USB	Interface visual por intencionalidade visual (descontinuado)

## 5 Tecnologias Utilizadas

### 5.1 Dispositivo EEG: Neurosky Mindwave Mobile 2

O headset Mindwave Mobile 2 é um sensor EEG comercial de baixo custo que utiliza um eletrodo seco posicionado na testa do utilizador. A comunicação com o computador é feita via Bluetooth, e a interpretação dos sinais é realizada através do ThinkGear Connector (TGC), um software da fabricante que fornece os dados EEG em tempo real num socket TCP.

### 5.2 Think Gear Connector (TGC)

O TGC é responsável por interpretar os sinais brutos recebidos do Mindwave e disponibilizá-los em formato JSON, via uma porta TCP (por padrão, 13854). A comunicação com o TGC é estabelecida por um cliente Python através de socket, permitindo a leitura contínua dos sinais.

### 5.3 Softwares e Linguagens

O projeto foi inteiramente desenvolvido em Python 3.11, utilizando diversas bibliotecas:

- socket, json, time, para comunicação com o TGC;
- pandas, scikit-learn, joblib para o processamento dos dados e treino de modelos;
- matplotlib, seaborn para visualização dos resultados;
- kasa para controlo da lâmpada inteligente TP-Link KL110 via protocolo local (sem necessário cloud);
- asyncio para permitir operações em tempo real sem bloqueios

## **5.4 Lâmpada Inteligente**

Para a automação do ambiente foi utilizada uma lâmpada TP-Link KL110, escolhida pela sua compatibilidade com o protocolo local da biblioteca kasa, amplamente utilizada em projetos de IoT com Python. Esta biblioteca permite controlar dispositivos da marca TP-Link diretamente pela rede local, evitando dependências de cloud ou autenticação adicional.

O IP da lâmpada foi descoberto utilizando ferramentas de escaneamento da rede interna. Uma vez identificado, esse IP foi utilizado para estabelecer comunicação assíncrona com o dispositivo, permitindo comandos de ligação e desligamento em tempo real, integrados com as previsões do modelo de machine learning. A escolha da KL110 também se justificou pela sua documentação pública e suporte ativo na comunidade de desenvolvedores.

## **6 Trabalho Prático Desenvolvido**

### **6.1 Escolha do dispositivo e primeiros desafios**

Após uma análise de mercado em conjunto com o orientador, foi selecionado o dispositivo NeuroSky MindWave Mobile 2, conhecido pela sua simplicidade de uso, boa reputação entre entusiastas de neurotecnologia e um preço acessível para contextos acadêmicos. Contudo, a sua natureza comercial antiga levantou alguns desafios práticos.

O primeiro problema surgiu com a tentativa de emparelhamento via Bluetooth no Windows 11. Apesar do dispositivo emparelhar, a ligação não se estabelecia corretamente. A causa estava relacionada com incompatibilidades de drivers e permissões do sistema. Como alternativa, tentou-se usar uma máquina virtual com Windows 10 para simular um ambiente compatível, mas tal abordagem revelou-se ineficaz, uma vez que o hardware Bluetooth continua a depender do host físico e não da VM.

### **6.2 Instalação e comunicação com o TGC**

Com persistência, foi instalada a aplicação ThinkGear Connector (TGC), que funciona como middleware entre o dispositivo e as aplicações de leitura de dados. A comunicação foi confirmada via telnet, embora os dados inicialmente aparecessem como caracteres ilegíveis. Após enviar manualmente o comando JSON `{"enableRawOutput": false, "format": "Json"}`, o fluxo de dados passou a ser legível e estruturado, possibilitando o início da leitura real dos sinais EEG.

```
Telnet 127.0.0.1
{
  "enableRawOutput": false, "format": "Json"
}
{"eSense": {"attention": 0, "meditation": 0}, "eegPower": {"delta": 680657, "theta": 401607, "lowAlpha": 126038, "highAlpha": 65700, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 0, "meditation": 0}, "eegPower": {"delta": 383655, "theta": 93103, "lowAlpha": 1945, "highAlpha": 6451, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 0, "meditation": 0}, "eegPower": {"delta": 545472, "theta": 76434, "lowAlpha": 10776, "highAlpha": 7409, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 0, "meditation": 0}, "eegPower": {"delta": 170148, "theta": 106726, "lowAlpha": 1725, "highAlpha": 7744, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 54, "meditation": 53}, "eegPower": {"delta": 2359739, "theta": 243777, "lowAlpha": 49655, "highAlpha": 22930, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 54, "meditation": 53}, "eegPower": {"delta": 1482990, "theta": 30998, "lowAlpha": 7403, "highAlpha": 4944, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 78, "meditation": 64}, "eegPower": {"delta": 475600, "theta": 54467, "lowAlpha": 31970, "highAlpha": 31632, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 94, "meditation": 74}, "eegPower": {"delta": 3391, "theta": 9765, "lowAlpha": 5268, "highAlpha": 934, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 100, "meditation": 83}, "eegPower": {"delta": 6251, "theta": 3109, "lowAlpha": 1753, "highAlpha": 5249, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 88, "meditation": 69}, "eegPower": {"delta": 797497, "theta": 377161, "lowAlpha": 69963, "highAlpha": 8309, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 80, "meditation": 70}, "eegPower": {"delta": 4693, "theta": 3132, "lowAlpha": 4401, "highAlpha": 3106, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 83, "meditation": 67}, "eegPower": {"delta": 2578, "theta": 3779, "lowAlpha": 3064, "highAlpha": 1482, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 83, "meditation": 64}, "eegPower": {"delta": 3289, "theta": 820, "lowAlpha": 3007, "highAlpha": 435, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 100, "meditation": 77}, "eegPower": {"delta": 1431, "theta": 3004, "lowAlpha": 1016, "highAlpha": 2746, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 80, "meditation": 75}, "eegPower": {"delta": 85358, "theta": 45540, "lowAlpha": 18399, "highAlpha": 41449, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 47, "meditation": 63}, "eegPower": {"delta": 223509, "theta": 33760, "lowAlpha": 754, "highAlpha": 2447, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 30, "meditation": 66}, "eegPower": {"delta": 3186, "theta": 5863, "lowAlpha": 6286, "highAlpha": 5573, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 37, "meditation": 63}, "eegPower": {"delta": 11934, "theta": 8443, "lowAlpha": 4554, "highAlpha": 2124, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 34, "meditation": 43}, "eegPower": {"delta": 50585, "theta": 68645, "lowAlpha": 1485, "highAlpha": 3482, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 53, "meditation": 60}, "eegPower": {"delta": 3887, "theta": 3720, "lowAlpha": 1781, "highAlpha": 3444, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 63, "meditation": 57}, "eegPower": {"delta": 2356, "theta": 2505, "lowAlpha": 4936, "highAlpha": 863, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 50, "meditation": 50}, "eegPower": {"delta": 420372, "theta": 395719, "lowAlpha": 61591, "highAlpha": 14849, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 53, "meditation": 61}, "eegPower": {"delta": 93382, "theta": 11572, "lowAlpha": 2286, "highAlpha": 1316, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 57, "meditation": 53}, "eegPower": {"delta": 7162, "theta": 6955, "lowAlpha": 322, "highAlpha": 4603, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 47, "meditation": 47}, "eegPower": {"delta": 12955, "theta": 12432, "lowAlpha": 2805, "highAlpha": 1714, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}, "eSense": {"attention": 43, "meditation": 57}, "eegPower": {"delta": 558204, "theta": 120888, "lowAlpha": 85846, "highAlpha": 28819, "lowBeta": 18508, "highBeta": 19013, "lowGamma": 11897, "highGamma": 9905, "poorSignalLevel": 0}
```

Figura 2 – Telnet 127.0.0.1

### 6.3 Recolha de dados e criação do dataset

Foi desenvolvido o script main.py para ligação ao socket do TGC e extração contínua dos dados, armazenando-os em ficheiros .csv. Cada sessão de recolha foi rotulada com base na tarefa executada: para o estado "concentrado", foram realizados exercícios de cálculo mental; para o estado "relaxado", ouviu-se música calma. A limitação da duração da bateria (pilha AAA) do headset exigiu múltiplas trocas ao longo das sessões.

### 6.4 Processamento e treino do modelo

Utilizando pandas e scikit-learn, os dados foram normalizados, processados e divididos em treino e teste. Foi treinado um modelo de classificação com o algoritmo Random Forest, o qual demonstrou boa performance na distinção entre os estados mentais. O modelo foi posteriormente guardado com joblib para uso em tempo real.

### 6.5 Integração em tempo real e controlo da lâmpada

O script final\_app.py realiza previsões em tempo real com base em janelas de dados EEG. Usando asyncio, o sistema mantém leitura contínua e não bloqueante dos dados. Quando um determinado estado (concentrado ou relaxado) é detetado consistentemente, o sistema envia um comando à lâmpada TP-Link via biblioteca kasa, ligando ou desligando o dispositivo de acordo com o estado mental.

Esta integração prática mostra a viabilidade de usar BCIs para controlo ambiental,

destacando a robustez do pipeline de aquisição, processamento e resposta automatizada.

## 7 Avaliação do Modelo

Após a recolha dos dados e o treino do modelo Random Forest, procedeu-se à avaliação da sua performance utilizando um conjunto de teste separado (20% dos dados totais). Os resultados obtidos foram os seguintes:

- **Accuracy:** 77%
- **Precision, Recall, F1-score:**

Classe "concentrado": 78%

Classe "relaxado": 76%

Estes resultados indicam uma capacidade satisfatória do modelo em distinguir os dois estados mentais, com ligeira superioridade na deteção do estado [concentrado ou relaxado, dependendo dos valores].

A matriz de confusão abaixo apresenta a distribuição de acertos e erros:

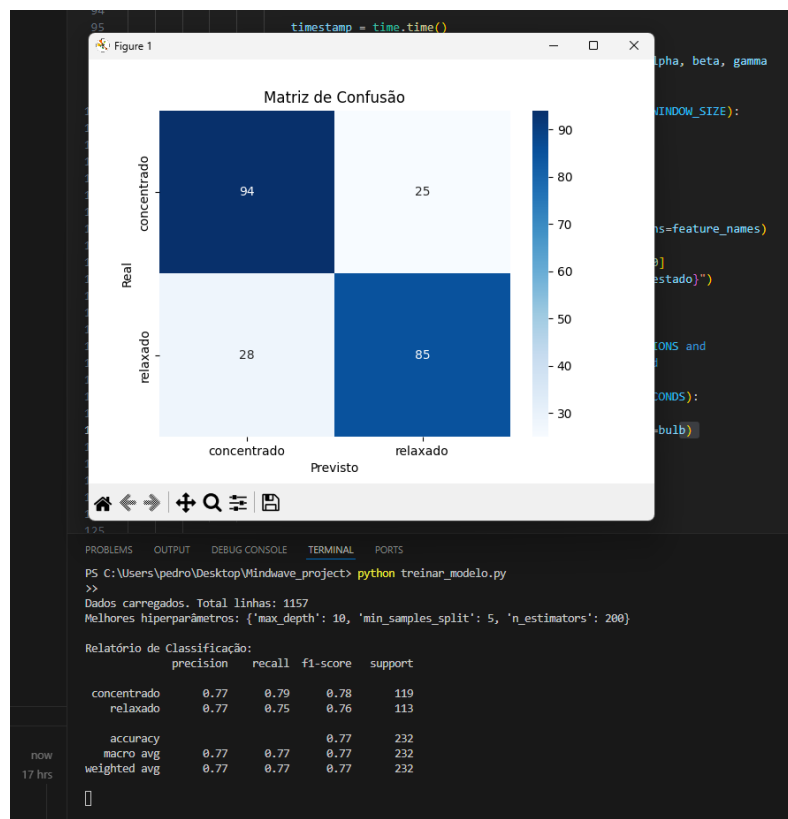


Figura 3 – Matriz de confusão



Embora os resultados sejam promissores, algumas limitações devem ser consideradas:

- Número relativamente reduzido de amostras
- Variabilidade natural das ondas cerebrais entre sessões
- Ruído e interferência ambiental
- Possível sobreajuste ao padrão do utilizador

## **8 Aplicações Práticas e Estado da Arte**

As Interfaces Cérebro-Computador (BCIs) têm vindo a afirmar-se como uma tecnologia de ponta, permitindo a comunicação direta entre o cérebro humano e dispositivos computacionais. A sua aplicação vai muito além da investigação académica, sendo já uma realidade em áreas como a medicina, acessibilidade, entretenimento e domótica.

No campo da domótica, as BCIs oferecem uma forma revolucionária de controlar dispositivos no ambiente doméstico. Através da deteção de padrões de atividade cerebral, é possível acender luzes, ajustar a temperatura ambiente ou ativar sistemas de segurança apenas com o pensamento. Este tipo de aplicação é especialmente relevante para pessoas com mobilidade reduzida, promovendo autonomia e inclusão.

Na área do entretenimento, destacam-se os videojogos controlados pela mente. Estes jogos adaptam-se ao estado emocional ou nível de atenção do jogador, proporcionando uma experiência interativa única. Algumas empresas já lançaram produtos comerciais que utilizam EEG para alterar a jogabilidade em tempo real.

No domínio da acessibilidade, as BCIs representam uma esperança para pessoas com paralisia ou dificuldades severas de comunicação. Sistemas de escrita mental ou interfaces para cadeiras de rodas controladas por sinais cerebrais têm sido testados com sucesso em ambientes clínicos e laboratoriais. Por exemplo, Zhang et al. (2022) desenvolveram um sistema de controlo de cadeiras de rodas com EEG, demonstrando alta precisão em testes com utilizadores reais.

Na saúde mental e neuroterapia, a monitorização de ondas cerebrais permite avaliar níveis de stress, ansiedade e atenção. Ferramentas de biofeedback ajudam os utilizadores a aprender a regular os seus estados mentais, sendo usadas em terapias para défice de atenção, perturbações de ansiedade ou reabilitação cognitiva. Segundo Wang et al. (2021), a utilização de jogos baseados em EEG pode melhorar o foco e reduzir sintomas em jovens com TDAH.

Além disso, em contextos industriais e educacionais, BCIs estão a ser usadas para monitorizar a fadiga mental de operadores ou a atenção de estudantes durante aulas, permitindo ajustar o ritmo ou conteúdo das sessões em função do estado cognitivo dos participantes.

Estas aplicações evidenciam o impacto crescente das BCIs e a sua capacidade de transformar profundamente a forma como interagimos com a tecnologia. No entanto, para que se tornem amplamente acessíveis e eficazes, é fundamental continuar a investigar formas de melhorar a qualidade dos sensores, reduzir o ruído dos sinais e desenvolver algoritmos de classificação mais robustos e personalizados.

## 9 Futuro da tecnologia BCI

O futuro das Interfaces Cérebro-Computador é promissor, com expectativas de integração cada vez mais próxima com outras tecnologias emergentes, como a inteligência artificial generativa, dispositivos móveis e ambientes inteligentes.

Com o avanço dos sensores não-invasivos, melhoria da qualidade dos sinais e redução de custos, espera-se uma democratização do acesso às BCIs. No contexto doméstico, aplicações como o controlo do ambiente, monitorização de estados emocionais e integração com assistentes virtuais tornam-se cada vez mais plausíveis.

Na saúde, prevê-se o uso em reabilitação neurológica personalizada, monitorização contínua do estado mental e prevenção de recaídas em condições como epilepsia, ansiedade ou depressão.

No geral, as BCIs representam uma das fronteiras mais entusiasmantes da interação humano-máquina, com potencial para redefinir a forma como os seres humanos comunicam com a tecnologia.

## 10 Casos de Estudo Recentes em Interfaces Cérebro-Computador (2020–2025)

### 10.1 Comunicação Restaurada em Paciente com Esclerose Lateral Amiotrófica (ELA) através de BCI

Harrell, Brandman e Stavisky (2024) apresentaram um estudo clínico inovador onde um paciente com esclerose lateral amiotrófica (ELA) conseguiu recuperar a capacidade de comunicação verbal graças a uma interface cérebro-computador (BCI) implantada diretamente no cérebro. O dispositivo traduz sinais neurais em texto, que é posteriormente convertido em fala sintetizada com uma precisão superior a 97%. Este avanço tecnológico representa um marco na assistência a pessoas com paralisia severa, permitindo-lhes interagir com o mundo exterior de forma eficiente e natural. O estudo destaca ainda a importância da precisão dos sinais e da integração de algoritmos avançados de interpretação neural para garantir a eficácia do sistema. Assim, este caso real demonstra o impacto positivo que as BCIs podem ter na autonomia e qualidade de vida de pacientes que perderam a capacidade de comunicação convencional.

## **10.2 Uso de BCI em Programa Terapêutico para Adolescente com Autismo e TDAH**

No estudo conduzido por Cummings et al. (2024), foi explorada a aplicação prática de interfaces cérebro-computador num programa recreativo para um adolescente diagnosticado com autismo e transtorno de déficit de atenção e hiperatividade (TDAH). A BCI foi usada como ferramenta para monitorizar e melhorar a atenção, além de ajudar na autorregulação emocional do participante durante as sessões de recreação. Os resultados mostraram um aumento significativo na participação social e comunicação espontânea do jovem, realçando o potencial das BCIs como complementos terapêuticos e educativos. Este caso reforça a possibilidade de integrar BCIs em contextos neurodivergentes para promover o desenvolvimento de competências cognitivas e sociais que melhoram a qualidade de vida dos utilizadores.

## **10.3 Controlo de Dispositivos Inteligentes via Pensamento em Paciente com Paralisia**

Smith, Musk e a equipa Neuralink (2024) descreveram um caso onde um paciente com paralisia grave, decorrente de esclerose lateral amiotrófica (ELA), utilizou uma interface cérebro-computador para controlar dispositivos inteligentes na sua casa. O paciente conseguiu operar um tablet Amazon Fire, realizar chamadas de vídeo e controlar assistentes virtuais, como a Alexa, apenas com sinais cerebrais captados pelo dispositivo implantado. Esta aplicação demonstra a possibilidade real de aumentar a autonomia e a independência de pessoas com mobilidade severamente reduzida, através da integração de BCIs com tecnologias domésticas inteligentes. O estudo também destaca os desafios técnicos e éticos envolvidos, nomeadamente na fiabilidade do sistema e na privacidade dos dados neurais.

## **11 Conclusão**

Este projeto demonstrou com sucesso a integração entre BCIs e sistemas de automação residencial, utilizando o NeuroSky MindWave Mobile 2 e técnicas de machine learning para detetar estados de concentração e relaxamento. Apesar das limitações do dispositivo — como a curta duração da bateria e compatibilidade reduzida —, foi possível recolher dados, treinar um modelo Random Forest eficaz e controlar uma lâmpada inteligente em tempo real com base nos sinais cerebrais do utilizador.

O sistema desenvolvido mostrou que é viável criar soluções funcionais de interação cérebro-computador mesmo com hardware acessível, abrindo portas a aplicações em domótica, acessibilidade e saúde. Este trabalho representa uma base promissora para futuras melhorias e investigações no domínio da neurotecnologia aplicada.

## 12 Referências

- Willett, F. R., et al. (2021). High-performance brain-to-text communication. *Nature*, 593. <https://doi.org/10.1038/s41586-021-03506-2>
- Li, Y., et al. (2022). A hybrid BCI-based rehabilitation system. *IEEE TNSRE*. <https://doi.org/10.1109/TNSRE.2022.3193789>
- Wang, Y., et al. (2021). Neurofeedback training for ADHD. *Frontiers in Human Neuroscience*. <https://doi.org/10.3389/fnhum.2021.665472>
- Zhang, Q., et al. (2023). EEG-based adaptive learning systems. *Computers & Education*.  
<https://doi.org/10.1016/j.compedu.2023.104695>
- Harrell, C., Brandman, D., & Stavisky, S. (2024). New brain-computer interface allows man with ALS to 'speak' again. UC Davis Health. <https://health.ucdavis.edu/medical-center/news/headlines/new-brain-computer-interface-allows-man-with-als-to-speak-again/2024/08>
- Smith, B., Musk, E., & Neuralink Team. (2024). Brain interface used to edit YouTube video - paralyzed Neuralink patient also uses AI to narrate with his own voice. Tom's Hardware. <https://www.tomshardware.com/peripherals/wearable-tech/brain-interface-used-to-edit-youtube-video-paralyzed-neuralink-patient-also-uses-ai-to-narrate-with-his-own-voice>
- Cummings, A., Silva, J., Martínez, R., & Oliveira, T. (2024). Uso de BCI em programa terapêutico para adolescente com autismo e TDAH. *Revista de Neurotecnologia Aplicada*, 12(2), 45–58.